

**ТЕХНИЧЕСКИ УНИВЕРСИТЕТ – СОФИЯ**

**ФАКУЛТЕТ „КОМПЮТЪРНИ СИСТЕМИ И  
ТЕХНОЛОГИИ“**



**ПРЕВРЪЩАНЕ НА ВЪПРОСИ НА ЕСТЕСТВЕН  
ЕЗИК ВЪВ ФОРМАЛНИ ЗАЯВКИ:  
МОРФОЛОГИЧЕН, СИНТАКТИЧЕН И  
СЕМАНТИЧЕН АНАЛИЗ СЪС СИНТЕЗ НА  
ПОТВЪРЖДАВАЩО ИЗРЕЧЕНИЕ**

**КУРСОВА РАБОТА**

**по дисциплина „Интерфейс на естествен език“**

**Разработил:**

Алекс Цветанов, фак. № **[TODO: фак. номер]**

Специалност: Компютърно и софтуерно инженерство, ОКС „Магистър“

**Преподавател:**

Доц. д-р Диана Григорова

София, 2027

# СЪДЪРЖАНИЕ

|                                                                   |           |
|-------------------------------------------------------------------|-----------|
| <b>УВОД</b>                                                       | <b>1</b>  |
| <b>I. АНАЛИЗ НА ПРЕДМЕТНАТА ОБЛАСТ И ЛИТЕРАТУРЕН ПРЕГЛЕД</b>      | <b>3</b>  |
| 1.1. Характеристики и особености на естествените езици            | 3         |
| 1.2. Математически модели на естествения език                     | 3         |
| 1.3. Психологически модели на езиковата обработка                 | 4         |
| 1.4. Модели за представяне на знания и съпоставителна оценка      | 4         |
| 1.5. Интерфейси на естествен език към бази от данни               | 4         |
| <b>II. АНАЛИЗ НА ВЪЗМОЖНИТЕ РЕШЕНИЯ И ОБОСНОВКА НА ИЗБОРА</b>     | <b>5</b>  |
| 2.1. Критерии за избор                                            | 5         |
| 2.2. Морфологичен слой: преобразувател срещу речник от словоформи | 5         |
| 2.3. Синтактичен слой: Earley срещу СУК                           | 5         |
| 2.4. Модел за представяне на знания                               | 6         |
| 2.5. Символно решение срещу базово решение с голям езиков модел   | 6         |
| <b>III. ПРОЕКТИРАНЕ НА СИСТЕМАТА</b>                              | <b>7</b>  |
| 3.1. Структура на интерфейса и изисквания към него                | 7         |
| 3.2. Морфологичен анализ                                          | 7         |
| 3.3. Синтактичен анализ                                           | 7         |
| 3.4. Семантичен анализ                                            | 8         |
| 3.5. Генериране на формална заявка                                | 8         |
| 3.6. Синтез на изречение                                          | 8         |
| <b>IV. ПРОГРАМНА РЕАЛИЗАЦИЯ</b>                                   | <b>9</b>  |
| 4.1. Обща структура на програмата                                 | 9         |
| 4.2. Реализация на морфологичния преобразувател                   | 9         |
| 4.3. Реализация на синтактичния анализатор                        | 9         |
| 4.4. Реализация на семантичния слой и на генератора               | 9         |
| 4.5. Тестове                                                      | 10        |
| <b>V. МЕТОДИКА ЗА ЕКСПЕРИМЕНТАЛНА ПРОВЕРКА</b>                    | <b>11</b> |

|                                                          |           |
|----------------------------------------------------------|-----------|
| 5.1. Цел на експеримента . . . . .                       | 11        |
| 5.2. Набор от въпроси . . . . .                          | 11        |
| 5.3. Мерки . . . . .                                     | 11        |
| 5.4. Съпоставка с базово решение . . . . .               | 11        |
| 5.5. Условия за валидност . . . . .                      | 12        |
| <b>VI. ЕКСПЕРИМЕНТАЛНИ РЕЗУЛТАТИ И АНАЛИЗ . . . . .</b>  | <b>13</b> |
| 6.1. Условия на измерването . . . . .                    | 13        |
| 6.2. Резултати по слоеве . . . . .                       | 13        |
| 6.3. Поведение при нееднозначност . . . . .              | 13        |
| 6.4. Съпоставка с базовото решение . . . . .             | 13        |
| 6.5. Анализ . . . . .                                    | 13        |
| <b>ЗАКЛЮЧЕНИЕ . . . . .</b>                              | <b>14</b> |
| <b>ЛИТЕРАТУРА . . . . .</b>                              | <b>15</b> |
| <b>ПРИЛОЖЕНИЯ . . . . .</b>                              | <b>17</b> |
| Приложение А. Формат на лексикалния запис . . . . .      | 17        |
| Приложение Б. Граматика на предметната област . . . . .  | 17        |
| Приложение В. Набор от въпроси за експеримента . . . . . | 17        |
| Приложение Г. Избрани откъси от изходния текст . . . . . | 17        |

## УВОД

Достъпът до структурирани данни изисква от потребителя да владее формален език за заявки. Това е бариера, която няма нищо общо със самия въпрос, който потребителят иска да зададе: човек, който знае какво търси в една база от данни, често не знае как да го напише на SQL. Интерфейсът на естествен език премахва точно тази бариера, като приема въпроса така, както той се формулира в обикновената реч, и произвежда формалната заявка вместо потребителя.

Настоящата курсова работа разработва такъв интерфейс под името *Lexicon*. Системата приема въпрос на естествен език, анализира го морфологично, синтактично и семантично, и генерира заявка на SQL или SPARQL срещу зададена предметна област. Обработката е изцяло символна: всяка стъпка от входното изречение до изходната заявка е представима, проверима и обяснима, което е съществено различие спрямо решенията, основани на статистически езиков модел.

**Целта** на проекта е да се изгради работеща верига от анализ и синтез, която превръща въпрос на естествен език във формална заявка и връща на потребителя перифраза на разбрания въпрос, за да може той да потвърди или отхвърли направеното тълкуване, преди заявката да бъде изпълнена.

За постигането на целта са формулирани следните **задачи**:

1. преглед на характеристиките на естествените езици, на математическите и психологическите им модели, и на моделите за представяне на знания, заедно със съпоставителна оценка между тях;
2. анализ на възможните решения за всеки слой от системата, лексикон и морфологичен анализатор, синтактичен анализатор, семантичен слой и генератор на код, и обосновка на направения избор;
3. проектиране на структурата на интерфейса и на договорите между слоевете;
4. програмна реализация на морфологичен анализатор върху краен преобразувател, синтактичен анализатор, работещ при нееднозначност, семантично изображение към модел за представяне на знания и генератор на формална заявка;
5. реализация на синтез на изречение, който перифразира изтълкувания въпрос;
6. изграждане на методика за експериментална проверка върху набор от въпроси и

съпоставка с базово решение, основано на голям езиков модел.

**Обхватът** на работата е ограничен до въпросителни изречения от предметната област, описана в лексикона и в модела на знанието. Извън обхвата остават свободен диалог, разрешаване на анафора през няколко реплики и произволна предметна област без предварително описание.

**Структура на изложението.** Раздел I разглежда предметната област и литературата. Раздел II излага разгледаните алтернативи и обосновава избора между тях. Раздел III представя проектирането на системата, а Раздел IV нейната програмна реализация. Раздел V описва методиката за експериментална проверка, а Раздел VI получените резултати. Заключението обобщава постигнатото и очертава посоките за по-нататъшна работа.

# **I. АНАЛИЗ НА ПРЕДМЕТНАТА ОБЛАСТ И ЛИТЕРАТУРЕН ПРЕГЛЕД**

## **1.1. Характеристики и особености на естествените езици**

Естественият език се различава от формалните езици по няколко свойства, всяко от които е пряка причина за инженерна трудност. Първото е *нееднозначността*: една и съща поредица от думи допуска повече от едно разчитане на всяко ниво, лексикално, морфологично, синтактично и семантично. Второто е *продуктивността*: множеството от допустими изречения е безкрайно, така че системата не може да работи със списък от разпознати въпроси. Третото е *контекстната зависимост*: значението на дадено изречение се променя от предходния текст и от предметната област.

Към тези свойства се добавят особеностите на българския език, който е силно флективен. Една лексема поражда десетки словоформи, а членуването, родът и числото носят синтактична информация, която в английския се изразява с ред на думите или със служебни думи. Това измества тежестта на анализа към морфологичното ниво: без надежден морфологичен анализатор синтактичният анализатор получава вход, в който почти всяка дума е неразпозната.

## **1.2. Математически модели на естествения език**

Математическото описание на езика започва от йерархията на формалните граматик и от въпроса къде в нея попада естественият език. Класическата постановка е дадена в [1] и въвежда генеративната граматика като модел на езиковата компетентност. За целите на инженерната реализация практическият избор почти винаги е безконтекстна граматика, разширена с признаци, защото за нея са известни ефективни алгоритми за анализ [2, 3], а изразителността ѝ покрива преобладаващата част от въпросителните конструкции.

На морфологично ниво съответният математически апарат е този на крайните автомати и на крайните преобразуватели. Преобразувателят изобразява повърхнинна словоформа върху лексикална форма заедно с граматични признаци и обратно, като едно и също устройство служи както за анализ, така и за синтез [4, 5]. Това двупосочно свойство е причината същият апарат да покрие и задачата за синтез на изречение в Раздел III.

### 1.3. Психологически модели на езиковата обработка

Психолингвистичните модели описват как човек обработва изречение в реално време и имат пряко отражение върху избора на алгоритъм. Инкременталността, тоест изграждането на частична интерпретация още преди изречението да е завършило, е наблюдавана при човешкия анализ и е свойство и на алгоритъма на Earley [2]. Мрежите с преходи [6] са ранен опит да се съчетае изчислителен модел с психологическа правдоподобност. **[TODO: допълнителен източник за психологическите модели на разбиране на изречение, сверен по издателска страница]**

### 1.4. Модели за представяне на знания и съпоставителна оценка

Формалната заявка се произвежда срещу някакъв модел на знанието, така че изборът на този модел определя какво изобщо може да бъде попитано. Основните семейства са логиката от първи ред, семантичните мрежи и концептуалните графи, фреймовите представяния, релационният модел и графовите модели от типа RDF [7, 8]. Те се различават по изразителност, по цената на извода и по това колко естествено върху тях се изобразява резултатът от семантичния анализ. Съпоставителната оценка по тези критерии е дадена в Раздел II, където се обосновава и направеният избор.

### 1.5. Интерфейси на естествен език към бази от данни

Задачата има дълга история като самостоятелно направление. Обзорът в [9] систематизира архитектурите на символните системи и описва повтарящите се проблеми, преносимост към нова предметна област, обработка на нееднозначност и обратна връзка към потребителя. По-новите набори от данни и мерки за оценка [10, 11] дават общ терен, върху който символни и статистически решения могат да се сравняват. Обобщение на прегледаните подходи и позиционирането на настоящата разработка спрямо тях е дадено в **[TODO: таблица със съпоставка на прегледаните системи]**.

Отделно като свързана работа стои изследване на автора върху съпоставянето с регулярни изрази, което ползва същия апарат от крайни автомати като морфологичния слой тук. **[TODO: цитат на статията за съпоставяне с регулярни изрази]**

## II. АНАЛИЗ НА ВЪЗМОЖНИТЕ РЕШЕНИЯ И ОБОСНОВКА НА ИЗБОРА

### 2.1. Критерии за избор

Решенията се оценяват по пет критерия: покритие на конструкциите от предметната област, поведение при нееднозначност, обяснимост на резултата, цена на пренасяне към нова предметна област и сложност на реализацията в рамките на курсовата работа. Обяснимостта се извежда като отделен критерий, защото системата връща на потребителя перифраза на разбрания въпрос, а такава перифраза е възможна само ако тълкуването е достъпно като структура, а не само като краен низ.

### 2.2. Морфологичен слой: преобразувател срещу речник от словоформи

Първият вариант е пълен списък от словоформи с приписани признаци. Той е тривиален за реализация и бърз при търсене, но расте линейно с лексикона и не обработва дума, която не е в списъка. Вторият вариант е краен преобразувател над лексикон и правила за словоизменение [5]. Той изисква повече работа в началото, но е компактен, работи в двете посоки и позволява анализ на непозната дума по нейното окончание. Изборът е вторият вариант, защото синтезът на изречение в Раздел III се нуждае точно от обратната посока на същото устройство.

### 2.3. Синтактичен слой: Earley срещу CYK

Двата разгледани алгоритъма за анализ при нееднозначност са CYK [3] и Earley [2]. CYK е по-прост за реализация и има предсказуемо поведение, но изисква граматиката да бъде приведена в нормална форма на Чомски, което изкривява дървото на извода и усложнява семантичното изображение. Earley работи с произволна безконтекстна граматика, обработва изречението инкрементално и дава същата асимптотична граница в общия случай, като е по-бърз при еднозначни фрагменти.

**[TODO: окончателен избор между Earley и CYK след измерване върху набора от въпроси]** При всички положения изходът на слоя е компактна гора от изводи, а не едно дърво, защото изборът между разчитанията се прави едва след семантичната проверка.



## 2.4. Модел за представяне на знания

Съпоставката между релационен модел, фреймово представяне и графов модел от типа RDF се прави по критериите от подраздел 2.1. Релационният модел е близък до целевата заявка на SQL и не изисква допълнително изображение, но описва слабо йерархията от понятия. Графовият модел описва добре йерархията и се запитва със SPARQL, но налага допълнителен слой между семантиката и данните. Оформената съпоставка е дадена в **[TODO: таблица със съпоставителна оценка на моделите за представяне на знания]**, а проектът поддържа и двете цели, за да може разликата да бъде измерена, а не постулирана.

## 2.5. Символно решение срещу базово решение с голям езиков модел

Голям езиков модел произвежда SQL от въпрос без нито един от изброените слоеве. Тази алтернатива е разгледана изрично, защото е очевидната съвременна съперница на символния подход. Тя има по-широко покритие и не изисква лексикон, но има три съществени недостатъка за настоящата задача: не дава проверяема следа от входа до изхода, не може да обоснове защо е избрала едно разчитане пред друго, и се проваля по начин, който потребителят не може да забележи, тъй като изходът изглежда правдоподобен и когато е грешен.

Точно този контраст прави съпоставката интересна. Символната система има по-тясно покритие, но всяко нейно тълкуване е представимо, обяснимо и потвърдимо от потребителя преди изпълнение. Затова езиковият модел се използва тук като *базово решение* за сравнение върху един и същ набор от въпроси, а не като част от системата. Начинът, по който съпоставката се провежда, е описан в Раздел V.

## III. ПРОЕКТИРАНЕ НА СИСТЕМАТА

### 3.1. Структура на интерфейса и изисквания към него

Интерфейсът на естествен език е конвейер от четири анализиращи слоя и един синтезиращ. Входът е низ на естествен език, изходът е формална заявка заедно с перифраза на разбрания въпрос. Слоевете са морфологичен анализ, синтактичен анализ, семантично изображение и генериране на код, а синтезът стои встрани от конвейера и се захранва от семантичното представяне.

Изискванията към интерфейса са четири. Всеки слой приема и връща данни по описан договор, така че да може да бъде заменен без промяна в останалите. Нееднозначността се пренася нагоре по конвейера, вместо да се разрешава преждевременно чрез евристика на ниско ниво. Всяко тълкуване е проследимо назад до конкретните думи, които са го породили. Заявката не се изпълнява, преди потребителят да е потвърдил перифразата.

### 3.2. Морфологичен анализ

Морфологичният слой е краен преобразувател над лексикона. За всяка входна словоформа той връща множество от разчитания, всяко от които съдържа лексема, част на речта и граматични признаци. Множеството е от разчитания, а не единично разчитане, защото омонимията между словоформи е обичайна и разрешаването ѝ е възможно едва на синтактично ниво. Форматът на записа в лексикона и наборът от признаци са дадени в **[TODO: таблица с формата на лексикалния запис и набора от граматични признаци]**.

### 3.3. Синтактичен анализ

Синтактичният слой приема поредица от множества с разчитания и връща гора от изводи спрямо граматиката на предметната област. Граматиката описва въпросителните конструкции, именните и предложните групи, и съгласуването по род и число, което в силно флективен език отхвърля голяма част от паразитните разчитания още на този етап. Схемата на конвейера и потокът на данните между слоевете са показани на **[TODO: фигура със структурата на конвейера]**.

### 3.4. Семантичен анализ

Семантичният слой изобразява всяко синтактично дърво върху израз в избраното представяне на знания. Изображението е композиционно: значението на групата се получава от значенията на съставките ѝ и от правилото, което ги свързва. Разчитанията, които не се изобразяват върху нищо в модела на знанието, отпадат тук, и точно това отпадане е основният механизъм за разрешаване на нееднозначността в системата.

### 3.5. Генериране на формална заявка

Генераторът превежда логическата форма в SQL или в SPARQL. Той не съдържа евристики върху текста: работи изцяло върху вече проверената логическа форма, което е причината една и съща семантика да може да се насочи към две различни цели без промяна в предходните слоеве. Съответствието между конструкциите в логическата форма и конструкциите в двата целеви езика е дадено в **[TODO: таблица със съответствието между логическата форма и целевите езици за заявки]**.

### 3.6. Синтез на изречение

Синтезът произвежда изречение на естествен език от семантичното представяне и го показва на потребителя като перифраза на разбрания въпрос. Ролята му е контролна: ако системата е избрала грешно разчитане, потребителят вижда това преди изпълнението на заявката. Реализацията ползва обратната посока на морфологичния преобразувател за словоизменението и правилата на граматиката за реда на думите, тоест същите два ресурса, които обслужват и анализа.

## IV. ПРОГРАМНА РЕАЛИЗАЦИЯ

### 4.1. Обща структура на програмата

Реализацията е на C++20 и се изгражда с CMake. Разделението на директории следва слоевете от Раздел III: публичните договори са в `include/`, реализацията е в `src/`, лексиконът и граматиките са в `data/`, а тестовете са в `tests/`. Всеки слой е отделна единица за превод със собствен заглавен файл, така че зависимостите между слоевете са видими в списъка с включвания и не могат да се образуват мълчаливо. **[TODO: фигура с йерархията на типовете и зависимостите между единиците за превод]**

### 4.2. Реализация на морфологичния преобразувател

Преобразувателят се изгражда еднократно от лексикона при стартиране и се запитва за всяка входна словоформа. Изборът на C++20 е свързан с този слой: `std::span` и `std::string_view` позволяват целият анализ да работи върху изгледи към входния низ без копиране, а `constexpr` изчисленията пренасят част от изграждането на таблиците в момента на превода. **[TODO: листинг с представянето на прехода и с основния цикъл на анализа]**

### 4.3. Реализация на синтактичния анализатор

Анализаторът поддържа таблица от състояния и я допълва инкрементално за всяка позиция във входа. Резултатът се пази като гора от изводи със споделени поддървета, което избягва експоненциалното изброяване на разчитанията при нееднозначни изречения. **[TODO: листинг с представянето на елемента в таблицата и на гората от изводи]**

### 4.4. Реализация на семантичния слой и на генератора

Семантичното изображение е обиколка на дървото отдолу нагоре, при която на всеки възел се прилага правилото, свързано със съответната граматична продукция. Генераторът на код е посетител върху логическата форма с две реализации, една за SQL и една за SPARQL, зад общ договор. **[TODO: листинг с една семантична функция и със съответния ѝ изход в двата целеви езика]**

## 4.5. Тестове

Модулните тестове са на GoogleTest и покриват всеки слой поотделно, плюс тестове от край до край, които подават въпрос и сравняват получената заявка с очакваната. Наборът от въпроси, върху който работят тестовете от край до край, е същият, който се ползва и в експерименталната част, за да не се окаже, че системата е проверена върху едно множество, а измерена върху друго. **[TODO: брой тестове и покритие след реализацията]**

## V. МЕТОДИКА ЗА ЕКСПЕРИМЕНТАЛНА ПРОВЕРКА

### 5.1. Цел на експеримента

Експериментът проверява две твърдения. Първото е, че системата превръща вярно въпросите от предметната област във формална заявка. Второто е, че перифразата, върната на потребителя, съответства на действително построената заявка, тоест че потвърждението от страна на потребителя е информативно, а не формално.

### 5.2. Набор от въпроси

Наборът се съставя предварително и се замразява, преди да е проведено каквото и да е измерване. Той съдържа въпроси от предметната област, разпределени по вид на конструкцията, и включва изрично подмножество от нееднозначни въпроси, за които правилният отговор е повече от едно допустимо тълкуване. Съставът на набора по категории е даден в **[TODO: таблица със състава на набора от въпроси по категории]**.

### 5.3. Мерки

Използват се четири мерки. Точност на морфологичния анализ, измерена спрямо ръчно проверени разчитания. Дял на въпросите, за които правилният извод присъства в гората от изводи. Дял на въпросите, за които генерираната заявка връща същия резултат като еталонната заявка при изпълнение върху едни и същи данни. Дял на въпросите, при които перифразата съответства на построената заявка според ръчна проверка. Пълните определения на мерките са дадени в **[TODO: определения на мерките и на начина на преброяване]**.

### 5.4. Съпоставка с базово решение

Базовото решение е голям езиков модел, на който се подава същият въпрос и същото описание на схемата, и се иска заявка. То се оценява по същите мерки върху същия набор. Съпоставката се провежда при фиксирано описание на схемата, за да не се получи разлика, произтичаща от различен вход. **[TODO: конкретният модел, версията му и настройките, при които е проведена съпоставката]**

Отделно от количествения резултат се записва и качествено различие, което е

основната причина за съпоставката: за всеки грешен отговор се отбелязва дали причината за грешката е установима от изхода на системата. Този показател не се очаква да бъде симетричен между двете решения.

### **5.5. Условия за валидност**

Измерването се смята за валидно само ако наборът от въпроси не е променян след започване на измерването, ако еталонните заявки са съставени независимо от изхода на системата, и ако едно и също изпълнение върху едни и същи данни възпроизвежда същите числа. Всяко нарушение се отбелязва в Раздел VI заедно с резултата, който то засяга.

## VI. ЕКСПЕРИМЕНТАЛНИ РЕЗУЛТАТИ И АНАЛИЗ

### 6.1. Условия на измерването

**[TODO: апаратна и програмна среда, версия на компилатора, размер на лексикона и на набора от въпроси, дата на измерването]**

### 6.2. Резултати по слоеве

Резултатите по слоеве се представят в таблица с по един ред на слой и по една колона на мярка от подраздел 5.3. Целта на разбивката по слоеве е грешката да се отнесе към конкретен слой, вместо да остане обща за системата.

**[TODO: таблица с точност по слоеве: морфология, синтаксис, семантика, генериране]**

### 6.3. Поведение при нееднозначност

Подмножеството от нееднозначни въпроси се отчита отделно, защото за него правилният резултат не е един. Отчитат се броят разчитания, оцелели след семантичната проверка, и дали избраното от системата разчитане съвпада с очакваното.

**[TODO: таблица с броя разчитания преди и след семантичната проверка]**

### 6.4. Съпоставка с базовото решение

Съпоставката се представя в таблица с по един ред на мярка и по една колона на решение, следвана от разбивка на грешките по причина.

**[TODO: таблица със съпоставка между символната система и базовото решение]**

**[TODO: разбивка на грешките по причина за двете решения, с отбелязване дали причината е установима от изхода]**

### 6.5. Анализ

**[TODO: инженерна трактовка на получените резултати: къде системата се проваля, дали провалите са концентрирани в един слой, и какво следва оттук за покритието на лексикона и на граматиката]**



## ЗАКЛЮЧЕНИЕ

Проектът изгражда интерфейс на естествен език, който превръща въпрос от обикновената реч във формална заявка чрез морфологичен, синтактичен и семантичен анализ, и връща на потребителя перифраза на разбирания въпрос, преди заявката да бъде изпълнена. Всички слоеве са символни, което прави всяко тълкуване проследимо назад до думите, които са го породили.

**Предимства на решението.** Обяснимост на всяка стъпка, възможност за потвърждение от потребителя преди изпълнение, и общ ресурс между анализа и синтеза, тъй като морфологичният преобразувател работи в двете посоки.

**Недостатъци.** Покритието е ограничено от лексикона и от граматиката, а пренасянето към нова предметна област изисква ръчна работа по описанието на знанието.

**Резултати.** **[TODO: обобщение на измереното след провеждане на експеримента от Раздел V]**

**Посоки за по-нататъшна работа.** Разширяване на лексикона и на граматиката, разрешаване на анафора през няколко реплики, и хибридна схема, при която езиков модел предлага разчитане, а символният слой остава арбитър, който го проверява срещу модела на знанието и отговаря за перифразата.

## ЛИТЕРАТУРА

- [1] N. Chomsky, *Syntactic Structures*. The Hague: Mouton, 1957.
- [2] J. Earley, “An efficient context-free parsing algorithm,” *Communications of the ACM*, vol. 13, no. 2, pp. 94–102, 1970.
- [3] D. H. Younger, “Recognition and parsing of context-free languages in time  $n^3$ ,” *Information and Control*, vol. 10, no. 2, pp. 189–208, 1967.
- [4] M. Mohri, “Finite-state transducers in language and speech processing,” *Computational Linguistics*, vol. 23, no. 2, pp. 269–311, 1997.
- [5] K. R. Beesley and L. Karttunen, *Finite State Morphology*. Stanford, CA: CSLI Publications, 2003.
- [6] W. A. Woods, “Transition network grammars for natural language analysis,” *Communications of the ACM*, vol. 13, no. 10, pp. 591–606, 1970.
- [7] J. F. Sowa, *Knowledge Representation: Logical, Philosophical, and Computational Foundations*. Pacific Grove, CA: Brooks/Cole, 2000.
- [8] W3C SPARQL Working Group, “SPARQL 1.1 query language.” W3C Recommendation, 2013. <https://www.w3.org/TR/sparql11-query/>.
- [9] I. Androutsopoulos, G. D. Ritchie, and P. Thanisch, “Natural language interfaces to databases: An introduction,” *Natural Language Engineering*, vol. 1, no. 1, pp. 29–81, 1995.
- [10] J. M. Zelle and R. J. Mooney, “Learning to parse database queries using inductive logic programming,” in *Proceedings of the Thirteenth National Conference on Artificial Intelligence (AAAI-96)*, pp. 1050–1055, 1996.
- [11] T. Yu, R. Zhang, K. Yang, M. Yasunaga, D. Wang, Z. Li, J. Ma, I. Li, Q. Yao, S. Roman, Z. Zhang, and D. Radev, “Spider: A large-scale human-labeled dataset for complex and cross-domain semantic parsing and text-to-sql task,” in *Proceedings of the 2018 Conference on Empirical Methods in Natural Language Processing (EMNLP)*, pp. 3911–3921, 2018.

- [12] D. Jurafsky and J. H. Martin, *Speech and Language Processing: An Introduction to Natural Language Processing, Computational Linguistics, and Speech Recognition*. Upper Saddle River, NJ: Pearson Prentice Hall, 2 ed., 2009.

## ПРИЛОЖЕНИЯ

### Приложение А. Формат на лексикалния запис

[TODO: описание на полетата в един лексикален запис и пример за няколко записа, прочетени от действителния файл в data/]

### Приложение Б. Граматика на предметната област

[TODO: пълният набор от продукции, прочетен от файла с граматиката]

### Приложение В. Набор от въпроси за експеримента

[TODO: замразеният набор от въпроси заедно с еталонните заявки за всеки от тях]

### Приложение Г. Избрани откъси от изходния текст

Показват се само относимите откъси, а не целите файлове. Всеки откъс се чете от истинския файл при компилация с `\lstinputlisting`, тоест не може да се разминава с хранилището.

[TODO: откъсите от `src/` и `include/`, добавени с `\lstinputlisting` след реализацията]